

イラストで学ぶ音声認識 改訂第2版

1. はじめに

1.1 音声認識とは

1.2 音声認識の歴史

1.3 どこで役立つのか

1.4 何が難しいのか

1.5 音声認識の定式化と本書の構成








1.1 音声認識とは



- 音声認識の定義
 - 人間が声で話す言葉を文字に変換する技術
 - 機械可読な意味表現に変換するところまでを含む場合もある
- 音声認識における問題設定
 - 使用環境：クリーン／定常雑音下／非定常雑音下
 - 利用者：特定話者／不特定話者
 - 単語数：数百（コマンド）／数千（特定用途）／数万以上（汎用）
 - 出力：正確な書き起こし／理解結果

1.2 音声認識の歴史

技術



応用例



1980年代

1990年代

2000年代

2010年代


2020年代

1.3 どこで役立つのか


- ヒューマンインタフェースの一手段として
 - 携帯端末（スマート[フォン|ウォッチ|グラス]）や家電・スマートスピーカーなどへの入力手段
 - カーナビなど、ハンズフリーが要求される状況
- 情報蓄積・検索
 - 会議の議事録作成
 - テレビ放送・動画への字幕付与
 - 音声検索

1.4 何が難しいのか


- ・ 分野横断的な技術である



- ・ パターン認識問題の中でも最も難しいクラスの問題である




- ・ 実用化のためには多くのノウハウが必要である



1.5 音声認識の定式化と本書の構成

- noisy channel モデルと音声認識との対応



1.5 音声認識の定式化と本書の構成

- noisy channel モデルに基づく音声認識の定式化
 - 雑音込みの音声 S から最も確からしい単語列 $\hat{W}$ を求める

$$\hat{W} = \operatorname{argmax}_W P(W | S)$$

- 従来の音声認識
 - S から特徴量 X を取り出し，ベイズの定理を用いて計算しやすくする

$$\hat{W} = \operatorname{argmax}_W P(W | X) = \operatorname{argmax}_W P(X | W)P(W)$$

- 近年のニューラルネットワークを用いた手法
 - S に対して簡単な処理だけを施した X を入力とし， $P(W | X)$ を推定するモデルの学習を End-to-End で行う

1.5 音声認識の定式化と本書の構成

- 音声認識技術の難しさへの対処
 - 分野横断的な技術である
 - イラストによる直観的な理解
 - パターン認識問題の中でも最も難しいクラスの問題
 - 単純なパターン認識から，WFSTによる認識，End-to-End 学習に至る段階的な解説
 - 実用化の際にノウハウが必要
 - 事前学習モデルや音声対話システム実装機能の紹介

1.5 音声認識の定式化と本書の構成

- 本書の構成

