

イラストで学ぶ音声認識 改訂第2版

5. ニューラルネットワーク


5.1 ニューラルネットワークとは

5.2 ディープニューラルネットワーク

5.3 畳み込みネットワーク


5.4 リカレントネットワーク

5.5 Transformer



5.1 ニューラルネットワークとは

- 生物の神経細胞の情報伝達をモデル化したユニットを組み合わせ、複雑な関数を近似するための数理モデル
 - 個々のユニットは複数の入力信号に異なる重みを掛けて足し合わせ、その値の大小によって活性／非活性が決まる非線形の情報変換を行う




5.1 ニューラルネットワークとは

- 非線形関数の実現
 - ユニットを階層的に組み合わせる（フィードフォワード型）
 - 出力と正解との誤差を最小化するように重みを調整する（誤差逆伝播法）


- 出力 $\hat{y}$ はネットワークの重み w によって決まるので、誤差関数は $L(w)$ と表現できる
- 誤差を最小化するための重みの更新式（ η は学習率）

- $w' \leftarrow w - \eta \frac{\partial L(w)}{\partial w}$



5.2 ディープニューラルネットワーク


- ディープニューラルネットワークとは
 - 多数の隠れ層を持つニューラルネットワーク
 - 大量のデータが利用可能になったことと、各種の工夫で学習が可能になった




$$\text{ReLU}(x) = \max(0, x)$$

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$


(1) 活性化関数の工夫



(2) 学習法の工夫



(3) スキップ接続



(4) バッチ正規化


5.2 ディープニューラルネットワーク

- 過学習への対処
 - ドロップアウト
 - 隠れ層のユニットを，一定の割合 p でランダムに無効化して学習
 - 学習後に実際の出力を計算するときは，重みを p 倍する

5.3 畳み込みネットワーク

- 畳み込みニューラルネットワーク (CNN)
 - 画像認識などのタスクで有効なアーキテクチャ
 - 畳み込み層とプーリング層を何段階か組み合わせて特徴抽出を行い、最後は密結合層で分類を行う
 - 畳み込み層
 - 入力データに対して、カーネルとよばれる小さなフィルタをスライドさせながら適用し、局所的な特徴を抽出する
 - プーリング層
 - 一定範囲の畳み込み層の出力に対して平均値あるいは最大値を求めることでダウンサンプリングし、特徴の位置依存性を緩和する

5.3 畳み込みネットワーク




5.4 リカレントネットワーク

- リカレントニューラルネットワーク（RNN）
 - 時系列データや自然言語など，順序が重要なデータに適したアーキテクチャ
 - 隠れ層の出力を次の時刻の入力と結合することで，過去の情報を保持した状態で出力を生成する
 - 自然言語処理の場合
 - 語彙数を次元数とする one-hot ベクトルで表現された単語は，200次元程度の低次元な埋め込みベクトルに変換される
 - 適切な出力が得られるように学習された埋め込みベクトルは，意味の近い単語同士のベクトル間の距離が近くなる

5.4 リカレントネットワーク

- LSTM (Long Short-Term Memory) ユニット
 - 単純な RNNでは離れたところにある情報を保持するのが難しい
 - LSTM は，過去の情報を保持するためのメモリセルと，情報の削除や追加を制御するゲートを持つ




5.4 リカレントネットワーク


- RNN の応用
 - RNN の最終状態に入力系列全体の情報を集約する**エンコーダ**と，そのベクトルを初期状態として出力系列を生成する**デコーダ**を結合して sequence-to-sequence (**seq2seq**) モデルが実現できる
 - さらに出力系列の生成の各時点において，入力系列のどの部分に注目するかを学習する**アテンション機構**を組み込むことで，より柔軟な出力生成が可能になった

5.4 リカレントネットワーク

- seq2seq モデルとアテンション機構



(a) 単純な seq2seq モデル




(b) アテンション機構の導入

行列 W は、次の出力単語を決めるときに、入力のどの単語を見ればよいかを学習することになります。



5.5 Transformer


- self-attention 機構を採用したエンコーダ・デコーダモデル



5.5 Transformer


- エンコーダ

- 入力トークン列を受け取り，各トークンに対する意味表現ベクトルを出力
- 位置情報を位置エンコーディングとして加える
- エンコーダブロックの内部



5.5 Transformer

- デコーダ
 - 部分的な出力結果を入力として受け取り，次の単語を予測
 - エンコーダブロックの処理結果を取り入れるクロスアテンション機構を持つ
 - デコーダブロックの内部



5.5 Transformer

- 大規模言語モデル
 - Transformer のエンコーダ部またはデコーダ部のみの構成で，入力の一部を予測する自己教師あり学習を行うことで，大規模なコーパスを用いた学習が可能になった
 - BERT (Bidirectional Encoder Representations from Transformers)
 - エンコーダ部のみを使用し，入力の一部をマスクしてその部分を予測する事前学習を行い，タスクに特化したデータでファインチューニングを行う
 - GPT (Generative Pre-trained Transformer)
 - デコーダ部のみを使用し，次の単語を予測する事前学習を行い，タスクに特化したデータでファインチューニングを行う