

イラストで学ぶ音声認識 改訂第2版

7. 統計的音声認識：音響モデル

7.1 音響モデルの単位


7.2 隠れマルコフモデルとは

7.3 隠れマルコフモデルの確率計算

7.4 状態系列の推定

7.5 パラメータの学習

7.6 高度な音響モデル




7.1 音響モデルの単位

- 音響モデル p (特徴ベクトル系列 | 単語列) の条件部
 - 単語列 (=文)
 - 可能な文が列挙できる小さなタスクでは有効
 - 数万語の語彙が必要なディクテーションでは、可能な文の数は膨大になるので、実質的にモデル化は不可能
 - 単語
 - 新しい単語がタスクに追加されるごとに、モデルを作成しなければならない
 - 音素
 - 単語辞書を音素系列で記述することで、大語彙に対応可能
 - 前後の音素情報を組み込んだトライフォンで音素をモデル化

7.2 隠れマルコフモデルとは


- 音響モデルのためのオートマトンの構造
 - 各状態で確率的にベクトルを出力し、確率的に状態遷移を行うムーア型オートマトン
 - 状態遷移が一方向に限定されている left-to-right 型の構造をもつマルコフモデルと解釈できる



7.2 隠れマルコフモデルとは

- 「隠れ」 マルコフモデル

- どの状態からどのベクトルが出力されたかという情報が隠れている




7.3 隠れマルコフモデルの確率計算

- 系列の出力確率
 - 例) 図7.4において $x = x_1x_2x_3x_4x_5$, 状態遷移 $S_1S_1S_1S_2S_2E$ の場合
$$P(X) = b_1(x_1) \cdot a_{11} \cdot b_1(x_2) \cdot a_{11} \cdot b_1(x_3) \cdot a_{12} \cdot b_2(x_4) \cdot a_{22} \cdot b_2(x_5) \cdot a_{2E}$$
 - すべての可能な状態遷移について求め、和を計算
- トレリス計算による効率化（前向きアルゴリズム）
 - 時刻 t , 状態 i における前向き確率 $\alpha_t(i)$ を, 入力的时间単位で順次計算
 - m はHMMの状態数


$$\alpha_t(i) = \left\{ \sum_{j=1}^m \alpha_{t-1}(j) a_{ji} \right\} b_i(x_t)$$

7.3 隠れマルコフモデルの確率計算




7.4 状態系列の推定

- ビタビアルゴリズム
 - 前向きアルゴリズムにおける系列の和の計算を，最大値演算に置き換える
 - 最大値を与えた経路を保存しておき，最終状態から逆にたどることで，最も確率の高い経路が得られる




7.5 パラメータの学習

- 状態遷移系列が既知の場合のパラメータ推定
 - 単純な最尤推定




7.5 パラメータの学習

- 状態遷移系列の確率が既知の場合のパラメータ推定
 - それぞれの最尤推定結果を重み付きでたし合わせる



7.5 パラメータの学習

- 状態遷移系列が未知の場合のパラメータ推定
 - EMアルゴリズムでパラメータをデータの分布に適合させる



この手順を、
Mステップの
パラメータが
安定するまで
繰り返します。



Mステップ：Eステップで得られた確率をもとに
図 7.10 の方法で HMM を学習

$$P(x_1 \mid x_2 \ x_3 \ x_4 \ x_5)$$

$$P(x_1 \ x_2 \mid x_3 \ x_4 \ x_5)$$

$$P(x_1 \ x_2 \ x_3 \mid x_4 \ x_5)$$

$$P(x_1 \ x_2 \ x_3 \ x_4 \mid x_5)$$

Eステップ：Mステップで得られた HMM で、
それぞれの状態遷移系列の確率を計算

7.6 高度な音響モデル

- 混合分布の学習
 - 各音素の特徴ベクトルは、一つの正規分布で近似できるほど単純ではない
 - 例) 男女差, 方言, ...
 - 複雑な確率密度関数を複数の正規分布の重み付き和で表現 → 混合分布
 - ϕ_i : i 番目の正規分布, w_i : i 番目の分布の重み, N : 混合数

$$\phi = \sum_{i=1}^N w_i \phi_i$$

- 重みはEMアルゴリズムで学習
- この方法を GMM-HMM (Gaussian Mixture Model-HMM) と呼ぶ

7.6 高度な音響モデル

- 識別的学習
 - 音素を区別するときの誤りを最小化するようにパラメータを学習
- DNN-HMM (Deep Neural Network-HMM)
 - $p(X | W)$ の学習を識別的に行う方法
 - HMMの各状態で特徴ベクトルを出力する確率 $b_i(x)$ を $p(x | s_i)$ とする
 - $p(x | s_i)$ にベイズの定理を適用

$$p(x | s_i) = \frac{p(s_i | x)}{p(s_i)} p(x)$$

- $p(x)$ は状態遷移に無関係なので定数とし, $p(s_i)$ は別途最尤推定
- $p(s_i | x)$ をDNNで学習

7.6 高度な音響モデル

- DNN-HMM

