

イラストで学ぶ音声認識 改訂第2版


9. 統計的音声認識：探索

9.1 音響モデルと言語モデルのギャップを埋める

9.2 状態空間の探索

9.3 WFST による音声認識

文法に従うと、最初の単語は地名です。その中で、「京都」と発声された確率が一番高そう。



「京都」に続く単語では、「の」の確率が高そうなので、これより後ろは「京都 の」に続く単語に絞って探索します。



9.1 音響モデルと言語モデルのギャップを埋める

- 音響モデルと言語モデルのギャップ
 - 音響モデル：音素単位（トライフォン）
 - 言語モデル：単語単位（文法 or N-グラム）
-発音辞書
 - 音素列 V と単語 W との対応
 - ある表記に対して複数の読みがある場合は，確率を $P(V \mid W)$ と表現
- 事後確率の計算式の見直し

$$\hat{W} = \arg \max_W p(X \mid V)P(V \mid W)P(W)$$


9.2 状態空間の探索

- 探索の必要性
 - 大語彙連続音声認識において、すべての W について、 $p(X | V)P(V | W)P(W)$ の値を求めるのは不可能
 - 音声の先頭から、スコアの高い候補に絞って、接続可能な展開をおこなう探索処理が必要
- 探索の効率化・高精度化の工夫
 - 木構造化辞書
 - ビームサーチ
 - マルチパス探索

9.2 状態空間の探索

- 音声認識における探索のイメージ

文法に従うと、最初の単語は地名です。
その中で、「京都」と発声された確率が一番高そう。




「京都」に続く単語では、「の」の確率が高そうなので、これより後ろは「京都 の」に続く単語に絞って探索します。




9.2 状態空間の探索

- 木構造化辞書で候補の展開数を削減
 - 単語単位で展開すると、候補は単語数個広がる
 - 単語間で先頭から共通する音素をまとめ、木構造化すると、展開数は音素数個



9.2 状態空間の探索

- ビームサーチで絞り込んで探索の実時間化
 - フレーム同期探索方式
 - HMMのトレリス空間において、1フレームごとにスコアを計算
 - ビームサーチ
 - 1フレーム単位で、残す探索候補の数を一定幅に制限



9.2 状態空間の探索


- マルチパス探索の目的
 - 事後確率最大となる単語列（最適解）を求めたい
- （単純な）ビームサーチの問題点
 - 全体としては最適となる解が，途中のスコアの低さでビーム幅から外れてしまう可能性がある
- マルチパス探索によって最適化を求める
 - 未探索部分のスコアをヒューリスティックスにより見積もって，最適解をビーム幅の中にとどめる
 - ヒューリスティックスは，探索に先立って高速な処理によって求める

9.2 状態空間の探索

- Julius の A* 探索



1 回目の探索は前から行い、粗いモデルで計算した値を残します。



2 回目の探索は、逆向きに、 $f = \hat{h} + g$ の値の高いものから展開します。




9.3 WFST による音声認識

- WFSTによるデコードのアイデア
 - 確率モデルのWFSTへの変換
 - 音声認識に用いる確率モデル（HMM，単語辞書，言語モデル）はWFSTで表現可能
 - WFSTの合成
 - 記号列Aを記号列Bに変換するWFST1と，記号列Bを記号列Cに変換するWFST2を合成すると，記号列Aを記号列Cに変換するWFSTになる
 - 最適化
 - WFSTには，FSAと同様，決定化・最小化のアルゴリズムが存在する

9.3 WFST による音声認識


- WFSTによる音声認識の概要




9.3 WFST による音声認識

- 音響モデルをWFSTに変換する
 - HMMをWFSTに変換

音素HMM




HMMから変換された
WFST



9.3 WFST による音声認識


- 音響モデルをWFSTに変換する
 - 連続値を入力とできるようにWFSTを分離



9.3 WFST による音声認識


- 発音辞書をWFSTに変換する
 - 単語表記と発音の関係は，単純に列挙すれば良いので，正規表現で記述可能
 - 実際は，音素列と単語列との対応の曖昧性を除去するために，各単語の最後にユニークな識別記号を付ける

明日	a s u	0.3
明日	a s h i t a	0.7



9.3 WFST による音声認識

- 言語モデルをWFSTに変換する
 - 言語モデルとして文法を用いた場合
 - 正規言語と見なせる場合が多いで、そのままWFSTで表現可能
 - N-グラムの場合
 - 長さ $N - 1$ の単語列を状態，N-グラム確率を重みとすることでWFSTで表現可能




9.3 WFST による音声認識

- WFST の合成
 - 確率の掛け算を足し算に置換
 - 確率の足し算を最大値処理に置換
- 半環による演算整合性の保証
 - トロピカル半環による抽象的演算


半環の名前	集合 K	加法 $\oplus$	乗法 $\otimes$	単位元 (加法)	単位元 (乗法)
確率	$[0, 1]$	$+$	$\times$	0	1
トロピカル	$[-\infty, +\infty]$	$\min$	$+$	∞	0

9.3 WFST による音声認識

- WFST の合成



ここでの半環は、
Tropical ですので、
 $\otimes$ は、通常の足し算
になります。




$a \rightarrow x$ の変換と、
 $x \rightarrow p$ への変換を
合成した重みは、
 $0.3 \otimes 0.8 = 1.1$
となります。




9.3 WFST による音声認識

- WFST の探索
 - 合成後の WFST に対して重み移動と最小化処理を行う
 - ビタビアルゴリズムでビームサーチ



重み移動



経路 0→1→3 の重みが 0.5, 経路 0→2→4 の重みが 1.4 なので, その最小値を初期状態まで移動させます.



残りは, 後の経路が確定する時点まで移動します.

